ME315_Lab08

João Victor Lima Moraes - 277176

Objetivo

Dados relacionais são uma constante no exercício da profissão do estatístico. Esta estratégia permite uma representação mais efetiva de dados estruturados, oferecendo a possibilidade de análises computacionalmente mais eficientes.

Leitura dos bancos

```
import polars as pl

basics = pl.read_csv("title.basics0.tsv.gz", separator="\t", null_values="\\N")
ratings = pl.read_csv("title.ratings.tsv.gz", separator="\t", null_values="\\N")
principals = pl.read_csv("title.principals0.tsv.gz", separator="\t", null_values="\\N")
```

Atividade

Utilizando apenas operações por meio da biblioteca polars, responda:

1. Quais são os 5 filmes com as maiores notas (averageRating)? Apresente uma solução capaz de desempatar os filmes baseando-se no número de votos recebidos.

```
top_5_filmes = (
    basics
    .filter(pl.col("titleType") == "movie")
    .join(ratings, on="tconst", how="inner")
    .sort(["averageRating", "numVotes"], descending=[True, True])
    .select(["primaryTitle", "averageRating", "numVotes"])
```

```
    .head(5)
)

print(top_5_filmes)
```

```
shape: (5, 3)

 primaryTitle               averageRating   numVotes
 ---                        ---             ---
 str                        f64             i64

 Kaveri                     10.0            1023
 Kurukku                    10.0            451
 Jedal Dar Omghe 30 Metri   10.0            142
 Sargashte                  10.0            134
 Gorgeous Rascal            10.0            115
```

2. Qual é o gênero mais frequente entre os filmes com nota maior que 8?

```
genero_mais_frequente = (
    basics
    .filter(pl.col("titleType") == "movie")
    .join(ratings, on="tconst", how="inner")
    .filter(pl.col("averageRating") > 8)
    .select("genres")
    .filter(pl.col("genres").is_not_null())
    .with_columns(pl.col("genres").str.split(","))
    .explode("genres")
    .group_by("genres")
    .agg(pl.len().alias("quantidade"))
    .sort("quantidade", descending=True)
    .head(1)
)

print(genero_mais_frequente)
```

```
shape: (1, 2)

 genres        quantidade
 ---           ---
```

```
str           u32

Documentary   10564
```

3. Quais são os 3 atores/atrizes que mais participaram de filmes com nota maior que 7.5?

```
top_3_atores = (
    basics
    .filter(pl.col("titleType") == "movie")
    .join(ratings, on="tconst", how="inner")
    .filter(pl.col("averageRating") > 7.5)
    .select("tconst")
    .join(principals, on="tconst", how="inner")
    .filter(pl.col("category").is_in(["actor", "actress"]))
    .group_by("nconst")
    .agg(pl.len().alias("participacoes"))
    .sort("participacoes", descending=True)
    .head(3)
)

print(top_3_atores)
```

```
shape: (3, 2)

 nconst      participacoes
 ---         ---
 str         u32

 nm0004660   231
 nm0595934   155
 nm3183374   124
```